포화 이전 예산에서의 단일 청크 최적성

Two-line 모델에서 선택 예산이 포화 길이보다 작으면, 모든 청크의 비용이 하나의 affine 식으로 표현된다. 이 조건에서 단일 청크의 비용 최소성을 정리하고, 중요도–지연시간 비율까지 전역 최적이 되는 충분조건을 살펴본다.

포화 이전의 비용 분해

행 수를 N, 행별 중요도를 $v_i \geq 0$이라 하자. 정확히 R개 행을 선택하는 mask $M \in \{0,1\}^N$에 대해

$$\|M\|_1 = R, \qquad I(M) = \sum_{i=0}^{N-1} v_i M_i, \qquad K(M) = |\mathcal{C}(M)|$$

로 둔다. 여기서 $\mathcal{C}(M)$은 선택된 행들의 최대 연속 구간 집합이다.

Two-line 모델에서 $\alpha \geq \lambda > 0$이고 $1 \leq R \leq N$, $R < \ell_0$라 하자. 모든 청크는 $|C| \leq R < \ell_0$를 만족하므로

$$T_{2\mathrm{L}}(|C|) = \lambda \ell_0 + (\alpha - \lambda)|C| = a + c|C|, \qquad a = \lambda \ell_0 > 0, \quad c = \alpha - \lambda \geq 0.$$

따라서 two-line 모델의 추정 읽기 비용을 $L(M)$이라 쓰면

$$\boxed{\begin{aligned} L(M) &= \sum_{C \in \mathcal{C}(M)} (a + c|C|) \\ &= aK(M) + cR. \end{aligned}}$$

같은 R에서는 전송 비용 cR이 고정되고, 청크가 하나 늘어날 때마다 비용이 정확히 a만큼 증가한다.

단일 청크의 비용 최소성

$R \geq 1$이므로 $K(M) \geq 1$이다. 따라서

$$\boxed{\min_{\substack{M \in \{0,1\}^N \\ \|M\|_1 = R}} L(M) = a + cR.}$$

길이 R의 단일 연속 구간은 항상 이 하한을 달성한다. $a > 0$이므로 청크가 둘 이상이면 비용이 엄격히 커진다. 따라서 비용 최소해는 모두 단일 청크이지만, 그 위치는 여러 곳일 수 있다.

이 결론은 읽기 비용에 대한 것이다. 여러 청크로 나누어 더 높은 중요도를 확보하면 $I(M)/L(M)$이 커질 가능성은 남아 있다.

중요도–지연시간 비율의 전역 최적성에 대한 충분조건

길이 R의 단일 구간 중 가장 큰 중요도를 I_1, 중요도가 가장 높은 R개 행의 중요도 합을 I_{top}이라 하자.

$$I_1 = \max_{0 \le j \le N-R} \sum_{i=j}^{j+R-1} v_i, \qquad I_{\text{top}} = \sum_{r=1}^{R} v_{(r)},$$

여기서 $v_{(1)} \ge \cdots \ge v_{(N)}$은 중요도를 내림차순으로 정렬한 값이다. 최선의 단일 구간을 선택한 mask를 M_1이라 하면

$$q(M_1) = \frac{I_1}{a + cR}.$$

한편 청크가 둘 이상인 모든 mask는 $I(M) \le I_{\text{top}}$이고 $L(M) \ge 2a + cR$이므로

$$q(M) = \frac{I(M)}{L(M)} \le \frac{I_{\text{top}}}{2a + cR}.$$

따라서 $I_{\text{top}} > 0$일 때 다음 조건이 성립하면, 최선의 단일 구간은 모든 다중 청크 해보다 비율이 작지 않다.

$$\frac{I_1}{a + cR} \ge \frac{I_{\text{top}}}{2a + cR} \quad \Longleftrightarrow \quad \boxed{\frac{I_1}{I_{\text{top}}} \ge \frac{a + cR}{2a + cR}.}$$

M_1은 단일 청크 해 중에서도 비율이 가장 크므로, 이 조건 아래에서는 정확히 R개 행을 선택하는 전체 문제의 전역 최적해다. 등호인 경우에는 다중 청크 해와 동률일 수 있다. $I_{\text{top}} = 0$이면 모든 중요도가 0이므로 모든 mask의 비율이 0이다.

위 조건은 충분조건이다. 성립하지 않더라도 단일 청크가 최적일 수 있다. 다중 청크 해가 중요도 상한 I_{top}과 비용 하한 $2a + cR$을 동시에 달성할 수 있다는 보장은 없기 때문이다.

896×128 실험에 대한 적용

실험 3.1의 KiB 단위 적합 계수는

$$\alpha_z \approx 0.183823\ \mu\text{s/KiB}, \qquad \lambda_z \approx 0.058754\ \mu\text{s/KiB}, \qquad z_0 = 208\ \text{KiB}$$

이다. 896×128 행렬은 원소당 2바이트이므로 한 행의 크기는 $w = 0.25$ KiB이고, 행 단위 전환점은

$$\ell_0 = \frac{z_0}{w} = 832$$

행이다. 행렬 전체는 224 KiB이지만, 실험 3.2의 요청 비율 $f \in \{0.1, 0.2, \ldots, 0.9\}$에서 선택 예산은 $R = \lfloor 896 f \rfloor$이다. 최대 예산은 806행, 즉 201.5 KiB이므로 모든 실험 예산이 $R < \ell_0$를 만족한다.

KiB 단위 기울기를 $c_z = \alpha_z - \lambda_z$라 두면, 행 단위 비용식의 계수는

$$a = \lambda_z z_0 \approx 12.221\ \mu\mathrm{s},$$
$$c_z \approx 0.125069\ \mu\mathrm{s}/\mathrm{KiB},$$
$$c = w c_z \approx 0.0312673\ \mu\mathrm{s}/\mathrm{row}.$$

따라서 고정 비용 a와 비교할 전송 비용은 $cR = c_z(0.25R)$이다. 대표 예산에 대입하면 다음과 같다. 표는 저장된 적합 계수의 `Two-line (free)` 값으로 계산하고 반올림하였다. 실제 충분조건의 판정에는 반올림 전 기준값을 사용한다.

요청 비율	선택 행 수 R	선택 크기 (KiB)	전송 비용 cR (µs)	$a/(cR)$	충분조건의 기준값 $(a + cR)/(2a + cR)$
10%	89	22.25	2.78	4.39	55.1%
30%	268	67.00	8.38	1.46	62.8%
50%	448	112.00	14.01	0.87	68.2%
70%	627	156.75	19.60	0.62	72.3%
90%	806	201.50	25.20	0.48	75.4%

예를 들어 10% 예산에서는 최선의 단일 구간이 Top-R 중요도의 약 55.1% 이상을 보존하면 비율 목적함수에서도 전역 최적이다.

이 충분조건은 two-line 비용 모델에 대한 것이며, 실제 trace에서의 성립 여부는 별도로 확인해야 한다.