

출연은 아이디어 ; VLM in a Flash를 읽고

• N : 순차적 weight를 channel의 갯수

• 파스스 $\mu \in \{0, 1\}^N$
 $\hookrightarrow$ channel on

• 논문의 (3.1)을 보면 latency model은

$$\hat{L}(\mu) = \sum_{c \in C(\mu)} T[|c|]$$

$C(\mu)$: μ 를 적용했을 때 생기는
 chunk들을 보는 것임.

$T[v]$: Flash Memory에서
 weight v 에 대한 I/O 시간.

• 파스스 μ 의 보편하는 importance의 값은.

$$I(\mu) = \sum_{i=0}^{N-1} v_i \mu_i$$

v_i : channel i 의 importance.

• 논문의 (3.2.1)을 보면 임계값을 초과하면 논문이 들어야 하는 특징을 나타냄.

$$\max_{\mu \in \{0, 1\}^N} \frac{I(\mu)}{\hat{L}(\mu)} \quad \text{s.t.} \quad \sum_{i=0}^{N-1} \mu_i \leq R$$

$R = \lfloor (1-\rho)N \rfloor$
 $\hookrightarrow$ sparsity

• (3.2.2)를 보면 chunk의 utility는

$$U(c) = \frac{I(c)}{\hat{L}(c)} = \frac{I(c)}{T(|c|)}$$

$I(c)$: sum of
 its neural importance.

• 그런데 이 문제의 최적해는 사실 찾기 어렵습니다.

$$\frac{I(M)}{\hat{L}(M)} = \sum_{c \in C(M)} \underbrace{\frac{T[l(c)]}{\sum_p T[l(c)]}}_{w_c} \cdot \underbrace{\frac{I(c)}{T[l(c)]}}_{\text{utility } U(c)}$$

• 그런데 $\sum_{c \in C(M)} w_c = 1$ 입니다.

• 즉, $\frac{I(M)}{\hat{L}(M)}$ 는 M 에 속한 각 chunk의 $U(c)$ 에 대한 weighted average 입니다.

• 따라서 $U(c)$ 가 가장 큰 chunk만 남기고

나머지를 discard 하는 것이 일의의 M 에 대해 최적입니다.

• 최적해는 무조건 chunk 개도 최소 가능하므로

utility가 가장 큰 chunk를 하나 고르는 것이 최적해입니다.

• chunk의 갯수는 $\binom{N+1}{2}$ 개이고

$$\text{값이 } R \text{ 이하로 제한하면 } \sum_{l=1}^R (N-l+1) = \frac{R(2N-R+1)}{2} \text{ 개입니다.}$$

• prefix sum으로 U 's 들의 누적합들을 $O(N)$ 에 미리 계산하면

$O(NR)$ 번의 탐색으로 $U(c)$ 가 가장 큰 chunk를 찾을 수 있습니다.

• 최적해의 형태가 이렇게 간단하다는 것은

흔히 큰 chunk가 사실 전혀 다른 종류의 문제라는 것을 강력히 시사합니다.

- 논증에서 M 을 고르는 알고리즘은 다음과 같습니다.

Step 1. Candidate Chunk Generation

- 후보 chunk length : $r_{\min}, r_{\min} + \Delta V, \dots, r_{\max}$.

•